

Análisis de redes sociales dinámicas de aprendizaje colaborativo

David Alarcón Rubio

dalarcon32@alumno.uned.es

Trabajo fin del máster de ingeniería y ciencia de datos
Universidad Nacional de Educación a Distancia



Director: Antonio Rodríguez Anaya

29 de junio de 2023

Contenidos

- 1 Introducción
- 2 Objetivos
- 3 Procesamiento de datos y técnicas de aprendizaje supervisado
- 4 Resultados Clave
- 5 Conclusiones

Aprendizaje colaborativo

- En un mundo cada vez más conectado, el aprendizaje colaborativo online se ha convertido en una herramienta poderosa para adquirir conocimientos y desarrollar habilidades [1].
- Las redes sociales de aprendizaje virtual se convierten en espacios donde los estudiantes pueden interactuar, colaborar y aprender unos de otros [2, 3].
- Los foros de una asignatura son mucho más que simples espacios para hacer preguntas y respuestas. Son entornos sociales dinámicos donde los estudiantes construyen conocimiento juntos [4].
- El análisis de redes sociales aplicado a los foros proporciona información valiosa sobre la participación de los estudiantes, lo que puede ser utilizado para monitorear su progreso de aprendizaje y predecir su rendimiento académico [5, 6].

Pregunta de investigación y motivación del estudio

¿Cómo podemos utilizar el análisis de redes sociales de aprendizaje colaborativo para predecir el abandono de los estudiantes?

En el ámbito educativo, el análisis de **redes sociales** y el **aprendizaje automático** pueden ser herramientas poderosas para comprender las interacciones entre los estudiantes y predecir el **abandono de asignaturas**.

Motivación del estudio

- Analizar las interacciones y la estructura social en una comunidad educativa en línea utilizando técnicas de análisis de redes sociales aplicadas a los foros de discusión de una asignatura.
- Desarrollar modelos de aprendizaje automático supervisado para predecir el abandono de los estudiantes en una asignatura, utilizando medidas de centralidad de la red social y medidas del sentimiento expresado en los mensajes.

Objetivos principales

Objetivo Principal: Evaluar la eficacia del análisis de redes sociales dinámicas en la predicción del abandono estudiantil en una asignatura.

- **Objetivo 1:** Analizar la eficacia de las predicciones basadas en el análisis de redes sociales, considerando diferentes rangos de tiempo desde el inicio del curso.
- **Objetivo 2:** Evaluar la eficacia del análisis de las redes temporales al subdividir el rango temporal en bloques de días seriados secuencialmente.
- **Objetivo 3:** Evaluar la eficacia del análisis de las redes temporales dinámicas al analizar bloques seriados dinámicamente o encadenados.

Rangos de tiempo

Se analizaron cuatro rangos de tiempo: 30, 60, 90 y 120 días. Estos rangos representan segmentos específicos de interacción en los foros de los estudiantes desde el inicio del curso.

Rangos de tiempo	Porcentaje de cobertura
30 días	25 %
60 días	50 %
90 días	75 %
120 días	100 %

Tabla 1.1. Porcentaje de cobertura por rango de tiempo.

Rangos de tiempo

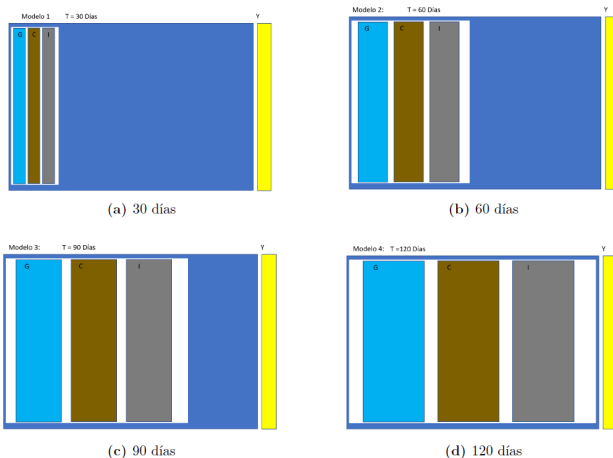


Figura 1.2. Rangos de tiempo utilizados en la predicción del abandono

Subdivisión en bloques

La subdivisión en bloques permite un análisis más detallado de la red social en segmentos específicos de tiempo [7]. Se consideraron diferentes rangos temporales y se determinaron las opciones de subdivisión en bloques.

Rangos	Número de días \times Número de bloques
30 días	$5 \times 6, 10 \times 3, 15 \times 2$
60 días	$5 \times 12, 10 \times 6, 15 \times 4, 20 \times 3, 30 \times 2$
90 días	$5 \times 18, 10 \times 9, 15 \times 6, 30 \times 3, 45 \times 2$
120 días	$5 \times 24, 10 \times 12, 15 \times 8, 20 \times 6, 30 \times 4, 40 \times 3, 60 \times 2$

Tabla 1.2. Subdivisión en bloques para cada rango temporal.

Subdivisión en bloques seriados secuencialmente




Figura 1.3. Subdivisión del rango de tiempo en bloques seriados secuencialmente

Subdivisión en bloques dinámicos o encadenados

- La subdivisión en **bloques secuenciales** permite analizar las interacciones y dinámicas dentro de cada bloque. La subdivisión en bloques dinámicos o encadenados establece una relación de continuidad entre los bloques, capturando la evolución y los cambios a largo plazo [8, 9].
- En la subdivisión en **bloques encadenados**, cada bloque temporal se superpone con el bloque anterior y el bloque siguiente.
- Esto significa que se comparten nodos y conexiones entre bloques adyacentes, lo que permite capturar la continuidad y los cambios graduales en la red a lo largo del tiempo.

Subdivisión en bloques dinámicos o encadenados




Figura 1.4. Subdivisión del rango de tiempo en bloques seriados dinámicamente (encadenados)

Subbjetivos e hipótesis: Teorías del Aprendizaje Social

Subobjetivo 1: Teoría del capital social de la red

Hipótesis A: Las medidas de centralidad ponderadas serán más capaces de capturar la importancia de las interacciones entre los nodos y predecir el abandono estudiantil [10, 11].

Subobjetivo 2: Teoría de la estructura social de la red

Hipótesis B: Los modelos de medidas de centralidad globales serán más eficaces para predecir el abandono estudiantil en comparación con los modelos que solo consideran medidas locales [12, 13, 8].

Subobjetivo 3: Teoría del balance social de la red

Hipótesis C: Las medidas de centralidad junto a las medidas de sentimiento expresadas en los mensajes podrán predecir el abandono estudiantil de manera más precisa [7, 14, 1].

Medidas de Centralidad en Redes Sociales

Medidas de Centralidad

- 1 **Grado (Degree)**: número de enlaces que tiene un nodo.
- 2 **Cercanía (Closeness)**: distancia promedio a los demás nodos.
- 3 **Intermediación (Betweenness)**: cuántas veces un nodo se encuentra en el camino más cortos entre otros nodos.

Medidas de Centralidad Ponderadas

- 1 **Sin pesos**: consideran solo la cantidad de nodos vecinos.
- 2 **Con pesos**: incluye la frecuencia de interacción con los nodos vecinos.

Medidas de Centralidad Locales y Globales

- 1 **Local**: mide la relación del nodo con sus vecinos directos.
- 2 **Global o híbridas**: mide las interacciones de los nodos vecinos a los que un nodo está conectado.

Medidas de Sentimiento y Emoción

Sentimiento

- Métrica utilizada para evaluar el **tono emocional** transmitido en los mensajes de texto. Asigna un valor numérico entre 0 y 1 representando la probabilidad de que el texto sea "positivo".

Russel Valence y Russel Arousal

- **Russel Valence**: Métrica que evalúa la carga emocional o la valencia de un texto.
- **Russel Arousal**: Métrica que evalúa el nivel de excitación o activación emocional transmitido por un texto.

Emoción

- Utiliza una **región de Russel** para clasificar el texto en categorías emocionales como neutro, relajado, feliz, triste o enfadado.

Algoritmos de aprendizaje y métricas de rendimiento

Algoritmos de aprendizaje supervisado:

- Regresión Logística
- SVM (Support Vector Machine)
- Decision Tree Classifier
- KNN (K-Nearest Neighbors)
- MLP Classifier (Multi-Layer Perceptron)

Métricas de evaluación de la predicción:

- Precisión (Accuracy)
- Precisión (Precision)
- Exhaustividad (Recall)
- Puntuación F1 (F1 Score)
- ROC AUC (Area Under the ROC Curve)

Índices de evaluación de las redes sociales dinámicas en la predicción

Evaluamos las teorías e hipótesis propuestas utilizando índices contruidos específicos.

- **Índice de amplitud o cobertura de la información:** mide la proporción del tiempo total de la asignatura cubierta por cada rango de tiempo analizado en los foros de los estudiantes.
- **Índice de unidad de información:** evalúa el grado de subdivisión en bloques que se utiliza para obtener las medidas de posición de los estudiantes y de expresión de sentimientos.
- **Índice de cantidad de información:** es una medida que combina el grado de subdivisión en bloques y la proporción de cobertura temporal en el análisis de redes sociales.

Resumen teorías, hipótesis e índices

Bloques	Medidas Ponderadas	Medidas Híbridas	Medidas Sentimiento
Bloque único	<p>Rango de amplitud de la información</p> <p>Tamaño de la unidad de información</p> <p>Cantidad total de información</p>		
Bloques secuenciales			
Boques dinámicos			

Figura 1.5. Resumen de teorías, hipótesis e índices

Modelos predictivos por combinación de factores

				NO EMOCIONES				EMOCIONES			
				NO HIBRIDO		HIBRIDO		NO HIBRIDO		HIBRIDO	
Total	Bloques	Días por bloque		NO PESOS	PESOS	NO PESOS	PESOS	NO PESOS	PESOS	NO PESOS	PESOS
30	1	30		1	2	3	4	5	6	7	8
60	1	60		9	10	11	12	13	14	15	16
90	1	90		17	18	19	20	21	22	23	24
120	1	120		25	26	27	28	29	30	31	32
30	2	15		33	34	35	36	37	38	39	40
30	3	10		41	42	43	44	45	46	47	48
30	6	5		49	50	51	52	53	54	55	56
60	2	30		57	58	59	60	61	62	63	64
60	3	20		65	66	67	68	69	70	71	72
60	4	15		73	74	75	76	77	78	79	80
60	6	10		81	82	83	84	85	86	87	88
60	12	5		89	90	91	92	93	94	95	96
90	2	45		97	98	99	100	101	102	103	104
90	3	30		105	106	107	108	109	110	111	112
90	6	15		113	114	115	116	117	118	119	120
90	9	10		121	122	123	124	125	126	127	128
90	18	5		129	130	131	132	133	134	135	136
120	2	60		137	138	139	140	141	142	143	144
120	3	40		145	146	147	148	149	150	151	152
120	4	30		153	154	155	156	157	158	159	160
120	6	20		161	162	163	164	165	166	167	168
120	8	15		169	170	171	172	173	174	175	176
120	12	10		177	178	179	180	181	182	183	184
120	24	5		185	186	187	188	189	190	191	192
30	2	15		193	194	195	196	197	198	199	200
30	3	10		201	202	203	204	205	206	207	208
30	6	5		209	210	211	212	213	214	215	216
60	2	30		217	218	219	220	221	222	223	224
60	3	20		225	226	227	228	229	230	231	232
60	4	15		233	234	235	236	237	238	239	240
60	6	10		241	242	243	244	245	246	247	248
60	12	5		249	250	251	252	253	254	255	256
90	2	45		257	258	259	260	261	262	263	264
90	3	30		265	266	267	268	269	270	271	272
90	6	15		273	274	275	276	277	278	279	280
90	9	10		281	282	283	284	285	286	287	288
90	18	5		289	290	291	292	293	294	295	296
120	2	60		297	298	299	300	301	302	303	304
120	3	40		305	306	307	308	309	310	311	312
120	4	30		313	314	315	316	317	318	319	320
120	6	20		321	322	323	324	325	326	327	328
120	8	15		329	330	331	332	333	334	335	336
120	12	10		337	338	339	340	341	342	343	344
120	24	5		345	346	347	348	349	350	351	352

Objetivo 1: Analizar la eficacia de las predicciones utilizando distintos rangos de tiempo

Rangos de tiempo (todos los tipos de subdivisión temporal).

Con un rango de 60 o 90 días se obtienen predicciones precisas del abandono.




Figura 7.1. Máximo Accuracy por rango temporal




Figura 9.1. Distribución de Accuracy por rango temporal

Objetivo 1: Analizar la eficacia de las predicciones utilizando distintos rangos de tiempo

Rangos de tiempo (todos los tipos de subdivisión temporal).

A medida que aumenta el porcentaje de **cobertura temporal**, la **eficacia** de todos los tipos de algoritmos también **incrementa**.




Figura 9.3. Eficacia de los algoritmos por rangos temporales




Figura 9.5. Índice de amplitud de la información

Objetivo 1: Analizar la eficacia de las predicciones utilizando distintos rangos de tiempo

Rangos de tiempo (todos los tipos de subdivisión temporal).

El **punto óptimo** de eficacia en la predicción se encuentra con valores previos al máximo nivel de unidad y cantidad de información.




Figura 9.6. Índice de unidad de información




Figura 9.7. Índice de cantidad de información

Objetivos 2 y 3: Analizar la eficacia de las predicciones utilizando distintos tipos de bloques temporales

Tipos de subdivisión en bloques temporales: secuenciales vs encadenados.

La precisión de los algoritmos con bloques **encadenados** es ligeramente superior, especialmente en los rangos de tiempo intermedios de **60 y 90** días.




Figura 9.10. Eficacia de los algoritmos por tipos de bloques




Figura 9.8. Eficacia por rangos de tiempo y tipos de bloques.

Objetivos 2 y 3: Analizar la eficacia de las predicciones utilizando distintos tipos de bloques temporales

Tipos de subdivisión en bloques temporales: secuenciales vs encadenados.

La subdivisión en bloques **encadenados** muestra una **eficacia superior** en comparación con la subdivisión en bloques **secuenciales**.




Figura 9.12. Índice de amplitud de información




Figura 9.13. Índice de unidad de información

Objetivos 2 y 3: Analizar la eficacia de las predicciones utilizando distintos tipos de bloques temporales

Tipos de subdivisión en bloques temporales: secuenciales vs encadenados.

La subdivisión en bloques **encadenados** aumenta la precisión (**Accuracy**) a medida que aumenta el **rango de tiempo** y el tamaño de **unidad** de la red.




Figura 9.14. Índice de cantidad de información




Figura 9.15. Cobertura y unidad de información

Subobjetivo 1: Analizar la eficacia de las predicciones utilizando medidas centrales ponderadas (con pesos)

Hipótesis del Capital Social Cognitivo

Las medidas de centralidad con **pesos** tienden a ser igualmente efectivas para todos los algoritmos y ligeramente superiores en rangos de tiempo superiores al 50 % (**entre 60 y 120 días**).




Figura 10.1. Eficacia por rangos de tiempo y tipos de medidas (ponderadas)




Figura 7.65. Eficacia de los algoritmos por tipos de medidas (ponderadas)

Subobjetivo 1: Analizar la eficacia de las predicciones utilizando medidas centrales ponderadas (con pesos)

Hipótesis del Capital Social Cognitivo

No se observan diferencias entre medidas de centralidad **sin pesos** y **ponderadas** para predecir el abandono de la asignatura.

Análisis de Accuracy de peso por cobertura de la información




Figura 10.3. Índice de amplitud de información

Análisis de Accuracy de peso por unidad de la información




Figura 10.4. Índice de unidad de información

Subobjetivo 1: Analizar la eficacia de las predicciones utilizando medidas centrales ponderadas (con pesos)

Hipótesis del Capital Social Cognitivo

Las medidas de centralidad con **pesos** tienden a ser más precisas cuando se dispone de una cantidad de información superior al **50 %**.




Figura 10.5. Índice de cantidad de información




Figura 10.6. Cobertura y unidad de información

Subobjetivo 2: Analizar la eficacia de las predicciones utilizando medidas centrales locales vs globales (híbridas)

Hipótesis de la Estructura Social Cognitivo

Las medidas de centralidad **globales** son igualmente precisas por tipo de algoritmos de aprendizaje supervisado, y ligeramente superiores a las **locales** cuando el rango de tiempo es mayor.




Figura 10.7. Eficacia por rangos de tiempo y tipos de medidas (híbridas)

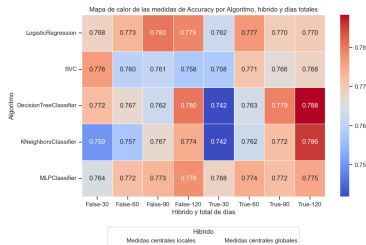


Figura 7.76. Eficacia de los algoritmos por tipos de medidas (híbridas)

Subobjetivo 2: Analizar la eficacia de las predicciones utilizando medidas centrales locales vs globales (híbridas)

Hipótesis de la Estructura Social Cognitivo

Las medidas de centralidad **globales** que evalúan la posición en la red de los nodos vecinos son ligeramente más eficaces para predecir el abandono de la asignatura.




Figura 10.9. Índice de amplitud de información




Figura 10.10. Índice de unidad de información

Subobjetivo 2: Analizar la eficacia de las predicciones utilizando medidas centrales locales vs globales (híbridas)

Hipótesis de la Estructura Social Cognitivo

Las medidas de centralidad **globales** tienden a ser más beneficiosas cuando se dispone de una mayor **cantidad** de información.




Figura 10.11. Índice de cantidad de información




Figura 10.12. Cobertura y unidad de información

Subobjetivo 3: Analizar la eficacia de las predicciones utilizando medidas centrales y de sentimientos.

Hipótesis del Balance Social Cognitivo

La precisión utilizando medidas de **centralidad** y de **sentimiento** conjuntamente es similar o superior con la mayoría de algoritmos de aprendizaje y mejor en los rangos de tiempo intermedios (50-75 %).




Figura 10.13. Eficacia por rangos de tiempo y tipos de medidas (sentimiento)




Figura 7.90. Eficacia de los algoritmos por tipos de medidas (sentimiento)

Subobjetivo 3: Analizar la eficacia de las predicciones utilizando medidas centrales y de sentimientos.

Hipótesis del Balance Social Cognitivo

El uso conjunto de medidas **emocionales** y de **centralidad** mejora la capacidad predictiva del modelo.




Figura 10.15. Índice de amplitud de información




Figura 10.16. Índice de unidad de información

Subobjetivo 3: Analizar la eficacia de las predicciones utilizando medidas centrales y de sentimientos.

Hipótesis del Balance Social Cognitivo

Las medidas de **centralidad** y de **sentimiento** conjuntamente pueden ser mejores para la predicción cuanto mayor **cantidad** de información.




Figura 10.17. Índice de cantidad de información




Figura 10.18. Cobertura y unidad de información.

Limitaciones y futuras investigaciones

- Tamaño limitado y sesgado de los datos analizados.
- Uso de medidas de cohesión de la red y algoritmos de detección de comunidades diferentes.
- Integración de medidas de centralidad y análisis de sentimiento para comprender la relación entre emociones y posición de los nodos.
- Utilización de técnicas de balanceo de datos, como SMOTE, para abordar el desbalance de los datos.
- Evaluación de la importancia relativa de las características mediante la técnica SHAP.
- Implementación de técnicas de ensamblaje, como Bagging o RandomForest.

Aplicación de los resultados

- ➊ Identificación temprana de estudiantes en riesgo: El análisis de la interacción en los foros de las asignaturas, considerando medidas de centralidad y evaluaciones emocionales, puede ayudar a identificar a los estudiantes que están en riesgo de abandonar la asignatura o que están experimentando dificultades académicas.
- ➋ Diseño de estrategias de enseñanza personalizadas: La comprensión de los patrones de comportamiento y las preferencias de los estudiantes en los foros de la asignatura puede guiar el diseño de estrategias de enseñanza personalizadas.
- ➌ Mejora de la experiencia del estudiante en entornos de aprendizaje en línea: El análisis de medidas de centralidad y evaluaciones emocionales en los foros de las asignaturas puede proporcionar información valiosa para mejorar la experiencia del estudiante en entornos virtuales.
- ➍ Desarrollo de sistemas de recomendación personalizados: La combinación de medidas de centralidad y emocionales puede ser utilizada para desarrollar sistemas de recomendación personalizados.

Análisis de redes sociales dinámicas de aprendizaje colaborativo

David Alarcón Rubio

dalarcon32@alumno.uned.es

Trabajo fin del máster de ingeniería y ciencia de datos
Universidad Nacional de Educación a Distancia



Director: Antonio Rodríguez Anaya

29 de junio de 2023

- [1] P. M. Moreno-Marcos, C. Alario-Hoyos, P. J. Munoz-Merino, I. Estevez-Ayres, and C. D. Kloos, "A Learning Analytics Methodology for Understanding Social Interactions in MOOCs," *IEEE Transactions on Learning Technologies*, vol. 12, no. 4, pp. 442–455, Oct. 2019. [Online]. Available: <https://ieeexplore.ieee.org/document/8550792/>
- [2] A. Soleymani, L. Itard, M. De Laat, M. Valle Torre, and M. Specht, "Using Social Network Analysis to explore Learning networks in MOOCs discussion forums," *CLIMA 2022 conference*, p. 2022: CLIMA 2022 The 14th REHVA HVAC World Congress, May 2022, publisher: CLIMA 2022 conference. [Online]. Available: <https://proceedings.open.tudelft.nl/clima2022/article/view/300>
- [3] M. De Lima and M. E. Zorrilla, "Social Networks and the Building of Learning Communities: An Experimental Study of a Social MOOC," *The International Review of Research in Open and Distributed Learning*, vol. 18, no. 1, Feb. 2017. [Online]. Available: <http://www.irrodl.org/index.php/irrodl/article/view/2630>
- [4] C. Karina, "Social Network Analysis in eLearning environments: a

- study of learner's interactions from several perspectives," Ph.D. dissertation, University of Alcalá, 2015.
- [5] C. Romero, M.-I. López, J.-M. Luna, and S. Ventura, "Predicting students' final performance from participation in on-line discussion forums," *Computers & Education*, vol. 68, pp. 458–472, 2013. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0360131513001607>
- [6] D. E. Froehlich, "Social Network Analysis in the field of Learning and Instruction: methodological issues and advances," Open Science Framework, preprint, Nov. 2018. [Online]. Available: <https://osf.io/ch8bj>
- [7] H. Kim and R. Anderson, "Temporal Node Centrality in Complex Networks," *Physical Review E: Statistical Physics, Plasmas, Fluids, and Related Interdisciplinary Topics*, vol. 85, p. 026107, 2012.
- [8] M. Elmezain, E. A. Othman, and H. M. Ibrahim, "Temporal degree-degree and closeness-closeness: A new centrality metrics for social network analysis," *Mathematics*, vol. 9, no. 22, p. 2850, Nov 2021. [Online]. Available: <http://dx.doi.org/10.3390/math9222850>

- [9] J. Tang, M. Musolesi, C. Mascolo, V. Latora, and V. Nicosia, "Analyzing information flows and key mediators through temporal centrality metrics," in *Proceedings of the 3rd workshop on social network systems*, New York, NY, USA, Apr. 2010.
- [10] Wasko and Faraj, "Why Should I Share? Examining Social Capital and Knowledge Contribution in Electronic Networks of Practice," *MIS Quarterly*, vol. 29, no. 1, p. 35, 2005. [Online]. Available: <https://www.jstor.org/stable/10.2307/25148667>
- [11] A. Barrat, M. Barthélemy, R. Satorras, and A. Vespignani, "The architecture of complex weighted networks," *Proceedings of the National Academy of Sciences of the United States of America*, vol. 101, pp. 3747–3752, 2004.
- [12] J. Krause, D. P. Croft, and R. James, "Social network theory in the behavioural sciences: potential applications," *Behavioral Ecology and Sociobiology*, vol. 62, no. 1, pp. 15–27, 2007. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7079911/>
- [13] A. Abbasi and L. Hossain, "Hybrid centrality measures for binary and

weighted networks,” in *The 3rd workshop on complex networks*. Germany: Springer: Berlin/Heidelberg, 2013, vol. 424, pp. 1–7.

- [14] C. M. Rawlings and N. E. Friedkin, “The Structural Balance Theory of Sentiment Networks: Elaboration and Test,” *American Journal of Sociology*, vol. 123, no. 2, pp. 510–548, Sep. 2017, publisher: The University of Chicago Press. [Online]. Available: <https://www.journals.uchicago.edu/doi/full/10.1086/692757>